Estimación preliminar de derivas sísmicas en edificios aporticados de concreto reforzado mediante generación paramétrica, verificación normativa automatizada y aprendizaje automático

Lucero · Alexis · Nicolás Infante Hernández · Jean Piere · Joseph

Equipo Nexo Sísmico · Beca AI Talent, 2.ª generación (AECODE) · Modalidad C: investigación académica aplicada · Octubre de 2026

Resumen. Comparar alternativas de predimensionamiento sísmico obliga a repetir la preparación de cargas, parámetros normativos y análisis estructurales. Este trabajo plantea un flujo reproducible con dos líneas de evidencia: una base paramétrica generada y analizada en OpenSees bajo la norma peruana E.030 (130 configuraciones en 49 familias) y una ruta colombiana NSR-10 compuesta por un módulo automatizado de verificación y una base de 18 edificios teóricos diseñados con el algoritmo del Prof. T. F. Rojas Vallejo. El módulo NSR-10, probado con un caso correcto, uno incompleto y uno erróneo, reproduce exactamente el cálculo de referencia del edificio del curso (cortante basal de 23,25 MN y derivas máximas de 0,985 % y 0,991 %) y bloquea las entradas defectuosas antes de calcular. Sobre la base NSR-10, con validación dejando una planta completa fuera, Random Forest estimó la deriva máxima con un error absoluto medio de 0,086 % en X y 0,101 % en Y, frente a 0,142 % y 0,166 % de la referencia, con predicciones en 32 ms. Con solo 18 casos el modelo detectó 3 de 7 edificios cercanos al límite, por lo que la herramienta sirve para ordenar alternativas, no para sustituir la verificación.

Palabras clave: deriva sísmica, Random Forest, NSR-10, E.030, OpenSees, automatización, predimensionamiento.

1. Introducción

En el predimensionamiento de edificios aporticados el ingeniero prueba varias combinaciones de luces, secciones y alturas antes de fijar un modelo definitivo. Cada alternativa exige recalcular cargas, espectro, fuerzas sísmicas y derivas, aunque la decisión que se busca sea solo descartar opciones que no cumplirán. El aprendizaje automático se ha propuesto para estimar respuestas estructurales a partir de variables de diseño y reducir esas iteraciones [5, 6], pero su utilidad depende de que los datos de entrenamiento sean trazables y de que la evaluación se haga sobre configuraciones no vistas.

Pregunta de investigación. *¿Con qué precisión Random Forest puede estimar las derivas máximas de familias de edificios aporticados no utilizadas durante el entrenamiento, y qué ventaja ofrece al comparar alternativas de predimensionamiento?*

Objetivo general: desarrollar y validar una herramienta predictiva de derivas sustentada en simulaciones documentadas. **Objetivos específicos:** (i) generar y analizar familias paramétricas; (ii) automatizar y validar la verificación NSR-10 con datos de SAP2000; (iii) consolidar una base de datos con procedencia explícita; (iv) evaluar Random Forest frente a referencias sencillas con partición por familias; (v) demostrar el prototipo con entradas correctas, incompletas y erróneas.

Ejes temáticos. Inteligencia artificial y aprendizaje automático (Random Forest y su validación); programación y automatización para AEC (generador, módulo NSR-10, exportaciones); simulación estructural (OpenSees y SAP2000); análisis y visualización de datos (base de datos, métricas y gráficos).

2. Metodología

El enfoque es cuantitativo y aplicado, basado en experimentación computacional. La Figura 1 resume la arquitectura: las dos rutas normativas se mantienen separadas porque difieren en espectro, rango de alturas e hipótesis de rigidez, y convergen en un mismo procedimiento de aprendizaje y evaluación.

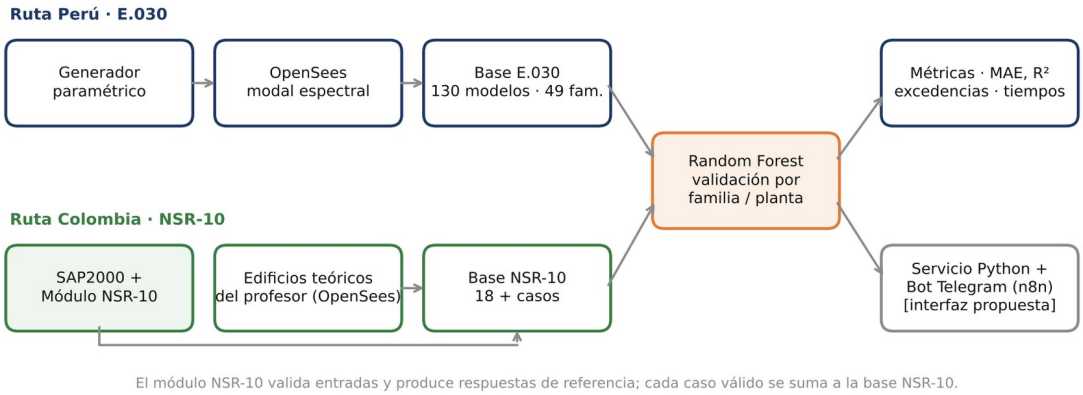


Figura 1. Flujo integrado de herramientas del proyecto.

2.1 Ruta E.030: generación paramétrica

Un generador en Python crea modelos tridimensionales en OpenSeesPy [3] de edificios regulares de dos a cinco pisos con diafragma rígido y masas por nivel, y los somete a análisis modal espectral según la E.030 [2]. Cada familia conserva el número de pisos y de vanos y varía secciones y cargas; la base actual reúne 130 configuraciones en 49 familias, de las cuales 43 superan el umbral de deriva de 0,007 en al menos un eje. Los modelos no reducen la rigidez por agrietamiento, simplificación que tiende a subestimar periodos y derivas.

2.2 Ruta NSR-10: módulo automatizado de verificación

El módulo *nexo_nsr10* (Python) recibe un archivo JSON con el sitio, el sistema, la geometría, los pesos por nivel, los periodos de SAP2000 y los desplazamientos de dos esquinas opuestas para 12 combinaciones de deriva (±Fx y ±Fy, sin torsión y con ±Mz accidental). Primero valida que existan todos los campos y que estén en rango; luego aplica la NSR-10 [1]: espectro de la Figura A.2.6-1 con coeficientes de microzonificación de Bogotá [7], periodo aproximado y límite Cu·Ta (A.4.2), cortante basal y distribución vertical (A.4.3), torsión accidental del 5 % (A.3.6.7), derivas $\Delta = \sqrt{(\Delta x^2 + \Delta y^2)}$ frente al 1,0 % de la altura de piso (A.6), índice de estabilidad Q (A.6.2.3) y coeficiente R con la revisión de irregularidad torsional (A.3.3). El caso de calibración es el edificio de oficinas de cinco pisos del curso de Diseño Estructural, grupo 1 (Bogotá, microzona Piedemonte A, Aa = 0,15, Av = 0,20, Fa = 1,65, Fv = 2,0).

2.3 Base de datos NSR-10 y aprendizaje

La base une, con un esquema común que registra fuente, norma, programa y estado del dato, 18 edificios diseñados con el algoritmo en OpenSees del Prof. T. F. Rojas Vallejo [8] (DES, suelo lacustre 200 de Bogotá, estructuras regulares) y los casos validados por el módulo. Las entradas de esos edificios (10 plantas regulares con relación de aspecto ≤ 1,5, dos alturas por planta entre 4 y 10 pisos, cargas del Título B y grupo de uso) fueron definidas por el equipo. Según el profesor, estos resultados son de carácter teórico: algunas plantas y luces no se resolverían con pórticos resistentes a momento en la práctica, y las dos configuraciones de la planta P9 se excluyeron por un error de dimensionamiento en el algoritmo.

Se entrenó Random Forest [4] (scikit-learn [9], 500 árboles, hoja mínima de 2, semilla 42) con 13 variables conocidas antes del análisis: altura, pisos, dimensiones y área de planta, número de columnas, luces máxima y media, cargas, coeficiente de importancia, esbeltez y un peso aproximado (área × pisos × carga muerta). Se comparó con una regresión lineal y con una referencia sencilla (Ta = 0,047·H^0,9 para el periodo y la media del entrenamiento para las demás respuestas). La validación dejó fuera una planta completa en cada uno de los 9 pliegues, de modo que las dos alturas de una planta nunca se reparten entre entrenamiento y prueba. Se reportan MAE, RMSE, R^2, el error porcentual medio y la detección de edificios con deriva ≥ 0,90 %, umbral práctico de revisión.

3. Resultados

3.1 Prototipo NSR-10: tres pruebas

Con la entrada completa, el módulo entregó Ta = 0,602 s, Cu·Ta = 0,764 s, Sa = 0,6187 g en la meseta del espectro, peso sísmico de 37,58 MN, cortante basal de 23,25 MN y derivas máximas de 0,985 % (X) y 0,991 % (Y), todas dentro del 1,0 % (Figura 2). Q máximo fue 0,0165 (no requiere P-Delta) y la relación Δmáx/Δprom = 1,193 quedó por debajo del 1,2 de irregularidad torsional, por lo que R = 5,0. Estos valores coinciden con el cálculo de referencia hecho con SAP2000 y hoja de cálculo. Al eliminar Fv, el módulo se detuvo e identificó el campo faltante; al introducir una altura libre de 350 (en centímetros), rechazó el valor e indicó el rango válido. Ninguna de las dos entradas defectuosas produjo resultados. Cada ejecución tardó menos de 1 ms.

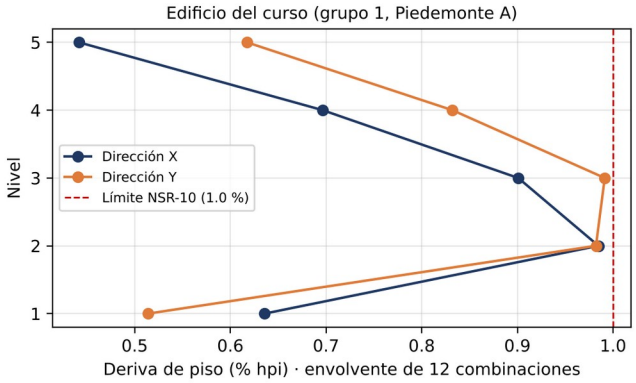


Figura 2. Derivas por nivel del edificio del curso: envolvente de 12 combinaciones en las esquinas E5 y A1.

3.2 Aprendizaje automático sobre la base NSR-10

La Tabla 1 resume el desempeño en plantas no vistas. Para las derivas, Random Forest redujo el error absoluto medio en 39 % (X) y 39 % (Y) respecto de la referencia y superó a la regresión lineal. Para el periodo y el cortante basal, la regresión lineal sobre variables físicas fue igual o ligeramente mejor, lo que es esperable con 18 casos y relaciones casi proporcionales a la altura y al peso. Ambos modelos mejoraron la fórmula Ta de la norma (error medio de 13,2 % frente a 9,2 % y 7,2 %). Las variables más influyentes en la deriva fueron el número de pisos, la altura y la esbeltez.

Respuesta	Random Forest MAE · R^2	Regresión lineal MAE · R^2	Referencia MAE · R^2
Periodo Tx (s)	0,070 · 0,79	0,062 · 0,85	0,104 · 0,63
Cortante Vx (kN)	2601 · 0,65	2399 · 0,66	4766 · -0,08
Deriva máx. X (%)	0,086 · 0,59	0,094 · 0,53	0,142 · -0,13
Deriva máx. Y (%)	0,101 · 0,42	0,130 · 0,11	0,166 · -0,15

Tabla 1. Error absoluto medio (MAE) y R^2 con validación dejando una planta fuera (18 edificios, 9 plantas). Derivas en % de la altura de piso.

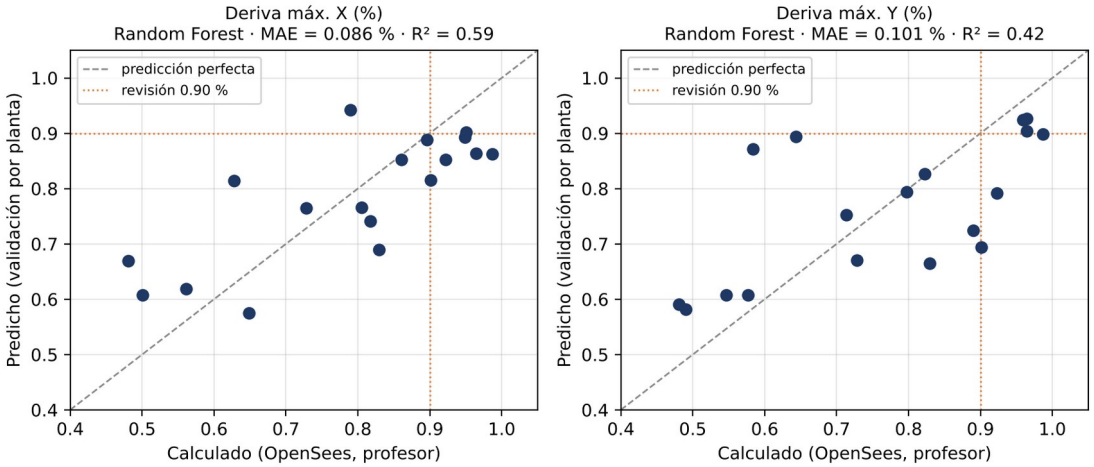


Figura 3. Deriva calculada (OpenSees) frente a predicha por Random Forest en plantas no vistas.

De los 7 edificios con deriva ≥ 0,90 %, el modelo identificó 3 y no generó falsas alarmas; los 4 restantes fueron subestimados (Figura 3). La predicción de un edificio tomó 32 ms y el entrenamiento de cada modelo unos 0,4 s.

4. Discusión

Los resultados responden parcialmente la pregunta. En la ruta NSR-10, Random Forest aproxima la deriva de configuraciones no vistas con un error del orden de una décima de punto porcentual, suficiente para ordenar alternativas, pero todavía no para afirmar si un edificio cercano al límite cumple: la tendencia a subestimar los casos más exigentes obliga a mantener la verificación con el módulo NSR-10 y SAP2000. Tres factores explican esta limitación: el tamaño de la muestra (18 casos), el carácter teórico de varios diseños del profesor y el hecho de que las derivas de diseño convergen cerca del límite, lo que reduce su variabilidad.

El módulo NSR-10 aporta lo que el predictor no puede dar por sí solo: respuestas de referencia trazables, validación de entradas y registros listos para ampliar la base. La evaluación del Random Forest sobre las familias reservadas de la base E.030, más numerosa, es la siguiente evidencia necesaria para generalizar; sus resultados no se mezclan con los de la ruta colombiana porque responden a otra norma, otro rango de alturas y otra hipótesis de rigidez. El ahorro de tiempo se manifiesta en la predicción (milisegundos por alternativa), pero no se cronometró el procedimiento completo de modelación en SAP2000, por lo que no se reporta un porcentaje de ahorro.

El trabajo se organizó en cinco frentes con responsables definidos (planteamiento, generación y OpenSees, módulo NSR-10, datos y Random Forest, validación y coordinación), con un repositorio común y un registro de decisiones que documenta las iteraciones, entre ellas el cambio de modalidad a investigación aplicada y la separación de las dos rutas normativas.

5. Conclusiones

- El módulo NSR-10 reproduce el cálculo de referencia del edificio del curso (Vs, fuerzas, derivas de 12 combinaciones, Q y R) y rechaza entradas incompletas o erróneas antes de calcular.
- Con validación por planta, Random Forest estimó la deriva máxima con MAE de 0,086 % y 0,101 %, un 39 % menos que la referencia, y mejoró la fórmula Ta en la estimación del periodo.

- Con 18 casos teóricos el modelo detecta 3 de 7 edificios cercanos al límite: sirve para priorizar alternativas, no para certificar cumplimiento.
- Los siguientes pasos son evaluar el modelo en las familias reservadas E.030, ampliar la base NSR-10 con casos verificados y conectar el módulo y el predictor al bot de Telegram como interfaz.

Referencias

[1] Asociación Colombiana de Ingeniería Sísmica. (2010). Reglamento Colombiano de Construcción Sismo Resistente NSR-10, Títulos A, B y C. Bogotá.

[2] Ministerio de Vivienda, Construcción y Saneamiento. (2018). Norma Técnica E.030 Diseño Sismorresistente. Lima.

[3] McKenna, F., Scott, M. H., & Fenves, G. L. (2010). Nonlinear finite-element analysis software architecture using object composition. Journal of Computing in Civil Engineering, 24(1), 95–107.

[4] Breiman, L. (2001). Random forests. Machine Learning, 45, 5–32.

[5] Sun, H., Burton, H. V., & Huang, H. (2021). Machine learning applications for building structural design and performance assessment: State-of-the-art review. Journal of Building Engineering, 33, 101816.

[6] Xie, Y., Ebad Sichani, M., Padgett, J. E., & DesRoches, R. (2020). The promises and challenges of machine learning in earthquake engineering. Earthquake Spectra, 36(4), 1769–1801.

[7] Alcaldía Mayor de Bogotá. (2010). Decreto 523 de 2010: microzonificación sísmica de Bogotá D.C.

[8] Rojas Vallejo, T. F. (2026). Algoritmo de diseño sísmico de pórticos de concreto reforzado en OpenSees [Código no publicado]. Universidad Nacional de Colombia.

[9] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.